

浙江大学

本科生毕业论文（设计）



中文题目：基于机器学习的无创血压值实时估计方法

英文题目：**Real-Time Noninvasive Continuous Blood
Pressure Estimation Using Machine Learning**

摘 要

心血管疾病已成为全球范围内致人死亡的头号病因。为了能有效预防心血管疾病，血压的连续测量尤为重要。目前，连续血压测量分为无创测量和有创测量两种方式。有创测量虽然能达到较高的精度，但是操作复杂且存在感染风险。无创测量主要基于脉搏波。随着机器学习的发展，愈来愈多的人使用脉搏波特征参数法。该方法主要存在两点问题。其一，手动提取特征对波形的要求较高，特征选取受研究者先验知识影响，极有可能提取到非相关特征。其二，血压波形中包含的丰富生理信息未能被充分挖掘。大多数研究的预测目标为收缩压、舒张压等单一血压值，较少的研究关注血压整体波形的预测。

针对上述问题，本文创新性地将原本用于二维图像处理的 U-Net 模型引入一维血压预测中，提出了一种基于 U-Net 的 PPG-ABP 转换模型。该方法无需手动提取特征，仅使用光电血管容积脉搏波（PPG）信号便可预测出连续血压波形。相较于脉搏波特征法，本文方法在信号获取和处理上更为便捷，在结果输出上包含更丰富的血压波形信息。本文平均血压预测结果满足美国医疗仪器促进协会（AAMI）标准。在英国高血压协会（BHS）标准下，舒张压与平均血压可达到等级 B。此外，本模型针对高血压与正常人群的血压分类也能取得较好的效果。

关键词： 无创测量，连续测量，动脉血压，光电血管容积脉搏波（PPG），U-Net

Abstract

Cardiovascular disease has become the significant cause of death. To prevent such disease effectively, continuous measurement of blood pressure is important. Nowadays, there are two ways of blood pressure measurement: noninvasive measurement and invasive measurement. Although invasive measurement can achieve high precision, it is complex to operate and has infection risk. The noninvasive measurement uses pulse waves. With the development of machine learning, many studies make handcrafted features from pulse waves to predict blood pressure. There are two problems with this method. Firstly, feature extraction requires a high standard for waveform, which is not easily achieved in reality. Besides, feature selection is influenced by prior knowledge of researchers. It is very likely to extract non-related features. Secondly, the abundant physiological information of the blood pressure waveform is not extracted fully. Specifically, most of the research aims to predict systolic pressure (SBP) and diastolic pressure (DBP). Indeed, less research focuses on the prediction of the overall waveform of blood pressure.

Given the above problems, the thesis introduces the U-Net model, originally used in two-dimensional image processing, into one-dimensional blood pressure prediction. A model based on U-Net was proposed, directly converting photoplethysmogram (PPG) to arterial blood pressure (ABP). The method does not need to extract the features manually. The continuous blood pressure waveform can be predicted only by using the PPG signal. In term of signal acquisition and processing, this method is more convenient. What's more, it contains more information of blood pressure waveform in the output. The results of the mean arterial pressure (MAP) prediction meet the AAMI standard. DBP and MAP can reach level B under the BHS standards. In addition, the model can also achieve ideal results in the classification of hypertension and normal people.

Keywords: Noninvasive measurement, continuous measurement, arterial blood pressure, photoplethysmogram (PPG), U-Net

目 录

致 谢	III
摘 要	IV
Abstract	V
目 录	VI
第 1 章 绪论	8
1.1 研究背景与意义	8
1.2 国内外研究现状	10
1.2.1 间断性测量	10
1.2.2 持续性测量	11
1.3 目前存在的主要问题	15
1.4 论文的主要研究内容	16
1.5 本章小结	17
第 2 章 脉搏波与动脉血压的联系及相关理论基础	18
2.1 动脉血压	18
2.1.1 动脉血压的基本概念	18
2.1.2 动脉血压的范围	19
2.2 脉搏波及其检测方法	19
2.2.1 脉搏波信号	19
2.2.2 检测方法：光电容积脉搏波描记法（PPG）	20
2.3 动脉血压与脉搏波的相关性	21
2.4 本章小结	21
第 3 章 数据预处理	22
3.1 数据来源	22
3.2 信号过滤	22
3.3 滑动窗提取波形	24
3.4 光电容积脉搏波和动脉血压的相位匹配	25
3.5 动脉血压目标值提取	27
3.6 光电容积脉搏波和动脉血压的降采样	27
3.7 归一化及拆分数数据集	28
3.7.1 归一化	28
3.7.2 数据集的拆分	29
3.8 本章小节	29
第 4 章 基于 U-Net 的连续血压模型	30
4.1 环境信息	31
4.2 模型	31
4.2.1 近似模型	33
4.2.2 优化模型	34
4.3 训练方法	36
4.4 本章小节	36
第 5 章 基于 U-Net 网络的连续血压模型的实现与结果分析	37

5.1 对比实验	38
5.2 结果检验	41
5.2.1 血压检验标准	44
5.2.2 血压分类	46
5.2.3 统计分析	47
5.3 与现有工作的比较	48
5.4 本章小结	49
第 6 章 总结与展望	51
6.1 工作总结	51
6.2 研究展望	52
参考文献	53
附录（可根据需要）	56
作者简历	57
毕业论文（设计）的进度安排	59

第 1 章 绪论

1.1 研究背景与意义

根据世界卫生组织（WHO）的报告，每年因心血管疾病 cardiovascular diseases, CVDs）而死的人数远高于其他疾病。毫无疑问，心血管疾病已成为危害人们健康的头号杀手。据世卫组织 2017 年的报告，每年有一千七百九十万人死于心血管疾病。这一数目相当于全球总死亡人数的 31%^[1]。在我国，随着老龄化的加剧，心血管死亡率也呈上升趋势。在死于心血管疾病的人群中，85%都是由于心脏病发作和中风。无论是患有心血管疾病的人，还是那些由多种因素（包括高血压、肥胖症或现有疾病）引起的心血管疾病高风险人群，都需要早期发现和预防。而预防的最重要参考指标便是血压。




图 1.1 1990~2017 年中国城乡居民心血管病死亡率变化

图片来源：中国心血管健康与疾病报告 2019 概要




图 1.2 2017 年中国农村居民（左）和城市居民（右）主要疾病死因构成比（%）

图片来源：中国心血管健康与疾病报告 2019 概要

血压是人体最重要的生理指标之一。血压会随着血液在心脏与动脉间的传播而变化。当心脏收缩时，血压达到最大值。当心脏扩张时，血压达到最低值。收缩压（systolic blood pressure, SBP）是血压波形的顶峰即最大值，舒张压（diastolic blood pressure, DBP）为血压波形的低谷即最小值。血压的变化和多种因素相关，例如饮食和精神状况。它和心脏的功能以及外围血管的功能密切相关，常被用来评估心血管状况。因此，连续的血压监控对于精确的诊断和进一步的治疗都是非常有必要的。




图 1.3 血压调节过程：心脏泵出->动脉->毛细血管->静脉^[2]

目前有一些能够精确测量血压的方法，然而为了达到测量精度，这些方法往往是有创的侵入式测量，穿戴这些测量设备极有可能带来伤口感染^[3]。对于有创测量，不仅需要专业的人员进行操作，而且会给本就脆弱的患者带来不必要的疼痛。医疗上现在多使用一种基于袖带的方法测量血压，但是由于该方法需要对袖带进行充气和放气^[4]，在长时间的测量时，会给患者带来极大的不便。

近年来，在临床上积累了大量的生物医学信号数据，越来越多的研究者开始以一种连续的、无袖的、无创的方式从生物医学信号中测定血压。随着研究的不断深入，该方法在血压测量的准确性和稳定性上都有了显著的提升^[5]。

1.2 国内外研究现状

血压测量的总体方法，如图所示。本研究主要针对无创血压，故后文的介绍将仅针对无创血压。无创血压技术主要含有间断测量和连续测量两种，下面将对此进行分别介绍。

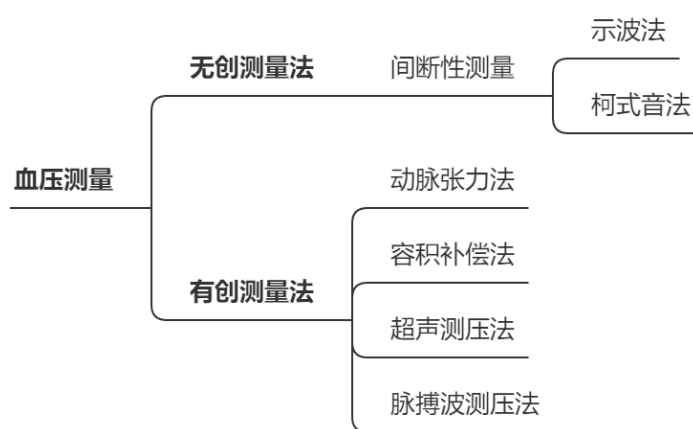


图 1.4 血压测量方法分类

1.2.1 间断性测量

间断测量主要包含两种，一种为柯式音法，另一种为示波法。

柯式音法由 Riva-Rocci 和 Korotkoff 在 20 世纪初所发明^[6]。测量方法主要分为以下步骤。（1）位于上臂的袖带在袖带中压力超过收缩压时阻塞肱动脉，即阻碍任何流经肱动脉的血液流动。其他的肢体，比如上肢也可以使用。（2）将听诊器置于袖带下方(远端)的动脉上。（3）逐渐放气臂套，直到听诊器听到第一个声音。臂套压力与收缩压相关联。（4）逐渐放气肱袖，直到听诊器上的任何声音完全消失。臂套压力最终与舒张压相关。其优点为准确度高，一直是测量的黄金标准。然而听诊测量需要人工操作者的干预，导致操作者之间存在较大的差异，并在一些情况下降低了血压读数的准确性。因此需要对操作人员进行定期培训，以达到目标测量精度。其次袖口的放气率以及袖口的尺寸和位置对测量的准确性也有很大的影响。

图 1.5 柯氏音法^[6]

示波法在 20 世纪 70 年代被发明^[7]，其主要步骤如下：（1）在上臂放置袖带，类似于柯氏听诊方法，在收缩压过高时闭塞肱动脉。（2）逐渐放气肱袖带直到舒张压下，并记录从肱动脉传递到袖带的压力脉冲。（3）联合处理记录在袖带的压力脉冲时间序列，以及施加在袖带上的咬合压力时间序列，以确定收缩压、平均压和舒张压值。其克服了柯氏音法中人为的误差因素，通过数字处理从动脉传到袖带的压力振荡来取代听诊器。然而该方法也仅限于间断测量，不能连续测量。

图 1.6 示波法^[7]

1.2.2 持续性测量

（1）动脉张力法

1963 年 Pressman 等^[8]提出了动脉张力法。其通过施加压力于桡动脉、股动脉等浅表动脉，改变血管壁内的周应力。利用压力传感器测量表面压力，并得到动脉压力波形。动脉血压值是当内外压力相等时，此时测量得到的外压力值。这种方法基本能达

到长时间的无创连续血压测量要求。它的优点是有一定的测量精度。但是其仍有三个难点（a）误差随生理状态改变而显著增大（b）难以长时间保持传感器位置不变^[9]（c）佩戴者舒适度较低。这是因为气囊加压装置需要长时间的测量，佩戴者需要一直保持静止状态。因此动脉张力计仍需改进运动测量、长期测量以及简化操作等方面的问题^[10]



图 1.7 使用动脉张力测定法的测量仪器^[8]

（2）容积补偿法

1976 年 PENAZ^[11]等提出了容积补偿法，1980 年 YAMAKOSHI 在容积补偿法的基础上设计出了手指血压测量系统^[12]。该方法的关键是预设参考压力值，使得血管壁满足零载荷。在零载荷状态下，动脉血管处于恒定容积状态，此时管壁直径不再随血压波动的变化而变化，测量此时的外加压力值便可得到血压值。该装置的压力来源为伺服系统，因此硬件设备复杂。此外，为避免被测人员静脉充血，只能进行短时间的测量。该方法的优点是能实时显示血压波形，测量速度快^[13]。

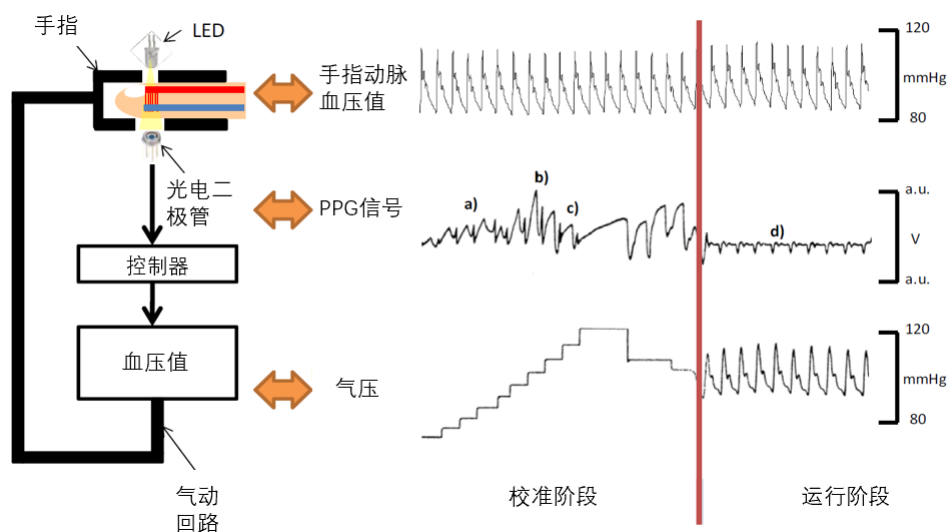


图 1.8 基于容积补偿法的手指血压测量系统^[12]

（3）超声测压法

超声测压法^[13]的原理是利用超声波在人体内血液循环过程中产生的多普勒效应，来间接测量收缩压和舒张压。这种方法需要相对复杂的测量设备，而且测量精确度不高，极易受肢体运动影响。收缩压是当超声波的多普勒频移初次被设备检测出来时，袖带所施加的压力；舒张压是当多普勒频移值明显降低时，袖带所施加的压力。

（4）脉搏波测压法

近年来，一些利用脉搏波的连续血压测量方法已经被提出。

脉搏波速测量法利用了脉搏波传导时间（PTT）来预测血压值。脉搏传导时间是两处动脉之间脉搏传递时间。其与脉搏传导速度（PWV）的倒数呈正比，如公式（1）所示：

$$PTT = \frac{D}{PWV} = D * \sqrt{\frac{2\rho r}{Eh}} \quad (1)$$

D 代表动脉上两个传感器之间的距离， r 表示动脉的半径， E 表示血管壁的弹性模量， ρ 表示血液在动脉中的密度， h 表示血管厚度^[14]。PTT 就是脉冲从两个位置间传播所花费的时间。这种方法通常需要两种物理信号，分别是心电图（ECG）和光电容积扫描计（PPG），Tanveer^[15]已证实了该方法的可行性。Yung-Hui Li 等^[16]提出了一种基于 ECG 和 PPG 信号提取的血压预测方法。所用特征包括了脉搏波传导时间（PPT），即心电图信号（ECG）的 R 波与 PPG 信号中收缩压之间的时间差值。然而，很多研究已经证实了心电图信号的 R 波并不能准确地表示脉搏波的开始，此外测量心电图信号（ECG）的设备十分复杂昂贵。

Carek^[17]等研究人员在腕表中结合 PPG 信号和心震图（seismocardiogram, SCG）信号，用以计算收缩压和舒张压。该设备需要一个高分辨率的三轴加速度传感器压在胸骨上，以测量心脏震动。然而，要开发和实现一个非常精确的加速度计传感器，并在可穿戴设备中放置并进行血压测量是十分困难的。作者使用 Moens-Kortweg 方程从 PPG 和 SCG 中计算出 PPT。但是用该方法求取 PPT 需要两个和被测者有关的参数。这两个参数对于每个被测者均不同，因此这就让血压的测量过程变得十分麻烦。此外，使用了两个不同的传感器来捕获 PPG 和 SCG，所以需要对两个信号进行校准以匹配时间差。

Chen 等^[18]提出了基于 PTT 方法和 PPG 波形特征的 SBP 和 DBP 估计模型。建立支

持向量机和多元线性回归模型预测模拟数据集上的 BP 值。研究了每个特征的影响值，并采用遗传算法对模型参数进行了优化，从包含 ECG、PPG 和 BP 信号的模拟数据库中提取了 772 组波形。首先清除 PPG 和 ECG 信号中的运动伪影、不规则节段和缺失波形。分别采用小波阈值去噪法和三次样条插值法对心电信号和 PPG 信号进行去噪。提取了 14 个特征，如 PTT、心率和其他描述 PPG 波形的特征。使用最小-最大定标器对所有这些特征进行归一化，并使用平均影响值（MIV）研究每个特征的重要性，以去除冗余特征并降低输入维数。

考虑到使用信号组合的困难，并且 PPG 是可穿戴设备中使用最方便的信号，目前很多研究人员试图仅使用 PPG 信号测量血压。Teng 和 Zhang^[19]利用 4 个从 PPG 信号中提取出的特征向量估测 SBP 和 DBP。并发现舒张时间（diastolic time）和 SBP 以及 DBP 的相关性更高。Wang 和 Wei^[20]，从 PPG 信号中提取了 22 个特征，以确定收缩压和舒张压的输出。Xie 等^[21]使用处理过的 PPG 信号的 8 个特征作为不同机器学习方法的输入，输出为 SBP 和 DBP。然而提取哪些合适的特征，以及如何高效地提取特征也是这些研究中亟待解决的问题。此外，基于特征的血压预测，要求血压的波形是理想波形，对于一些异常波形，不能很好地提出特征。

Mlakar 等^[22]使用预处理过的原始 PPG 信号窗口以及一阶和二阶导数作为基于 ResNet-Gru 网络的输入，以此预测血压。然而由于栅格循环单元（GRU）的学习效率较低且收敛速度较慢，这种基于 ResNet-Gru 的模型计算成本较高。Shota^[23]等使用卷积神经网络（CNN）模型得到收缩压和舒张压。上述方法并不满足医疗器械进步协会（AAMI）的标准误差范围。

与以前的 PPG 时域方法不同，Xing 和 Sun^[24]引入了一种从 PPG 信号中提取特定特征的频域方法。将快速傅立叶变换（FFT）应用到 PPG 上，提取波幅和形状等基本特征。然而该方法的特征提取存在一定的局限性。当 BP 值发生快速变化时，特征会受到相邻拍的影响，从而降低 BP 估计的精度。

Dey 等人^[25]开发了一套基于人口统计学和生理学特征的 BP 估计模型。一组独特的 PPG 特征也被纳入了使用 lasso 回归模型估计 SBP 和 DBP 的模型中。作者从 205 名具有不同人口学和生理学特征的志愿者身上收集了他们的 PPG 信号。从单个心跳（一个 PPG 脉冲）中提取了 233 个时域和频域特征。对 PPG 信号的前四阶导数进行特征提取。其他特征、人口统计学和生理学信息（年龄、身高、体重、性别）也被用作独立

特征。为了充分利用人口统计学和生理学特征，数据集根据年龄、性别和 BMI 分别进行了划分，对每个分区应用回归模型。结果表明，在人口统计学和生理学特征的基础上加入多个独立的划分，可以进一步提高 BP 估计值。

1.3 目前存在的主要问题

目前无创血压主要分为间断性测量和持续性测量。其中，持续性测量由于可以连续测量血压、更好地帮助发现血压异常而广受研究。在持续性测量中主要分为四种方法：动脉张力法，容积补偿法，超声测压法，脉搏波测压法。目前脉搏波测压法被广为研究，这种方法的输入数据主要来源于 ECG 和 PPG。诸如线性回归、支持向量机、长短期记忆人工神经网络等方法均被引入脉搏波测压法中。

表 1.1 六种血压测量方法对比

技术名称	是否阻塞血管	是否人工监督	周期	精度
柯氏音法	是	是	间断测量	黄金准则
示波法	是	否	间断测量	好
动脉张力法	部分	否	连续	较低
容积补偿法	部分	否	连续	有争议
超声测压法	否	否	连续	较低
脉搏波测压法	否	否	连续	有争议

目前关于脉搏波测压法的技术难点主要如下：

- (1) 如何高效地从脉搏波中选用特征参数。
- (2) 如何解决异常波形中难以提取有效特征的问题。
- (3) 如何减少传感器种类的使用，利用较少的信号个数推测血压。
- (4) 如何降低计算时间复杂度，提高预测精度。
- (5) 如何提升模型的泛化能力，解决模型仅预测特定人群血压的问题。
- (6) 如何有效进行信号预处理，去除脉搏波中的噪声。

1.4 论文的主要研究内容

本文提出了一种 PPG-ABP 直接转换模型，利用近似网络叠加优化网络的方法预测血压。该方法无需手工提取特征，仅使用光电血管容积脉搏波（PPG）便可预测出动脉血压（ABP）的全部波形。具体而言，先对来自重症监护医疗信息（MIMIC II）数据库中的光电血管容积脉搏波（PPG）和动脉血压（ABP）进行预处理。随后设计无创血压连续测量的模型，对 U-Net 和 MultiResUNet 分别进行改进，构建近似网络和优化网络，从而实现对于血压的连续预测。具体研究内容如下：

- （1）调研目前常见的血压测量方法，了解其原理和优缺点，总结归纳血压测量的方法和机器学习用于血压预测的研究现状，了解基本生理信号参数特点。
- （2）研究国内外论文，阐明电血管容积脉搏波（PPG）和动脉血压（ABP）的联系及相关理论基础。
- （3）研究信号预处理的方法，利用巴特沃斯、滑动窗、互相关函数、归一化等对信号进行处理。合理划分数据集，并对信号进行降采样。
- （4）设计 PPG-ABP 直接转换模型。设计基于 U-Net 的近似模型以及基于 MultiResUNet 的优化模型。验证深度监督对模型性能的提升。利用五折交叉验证，挑选最佳模型组合。在测试集上对最优模型结构进行训练和测试，并利用美国医疗仪器促进协会（AAMI）、英国高血压协会（BHS）等标准对结果进行衡量。基于模型预测结果，利用混淆矩阵，检验血压分类效果。最后对预测结果进行一致性及相关性等统计分析。

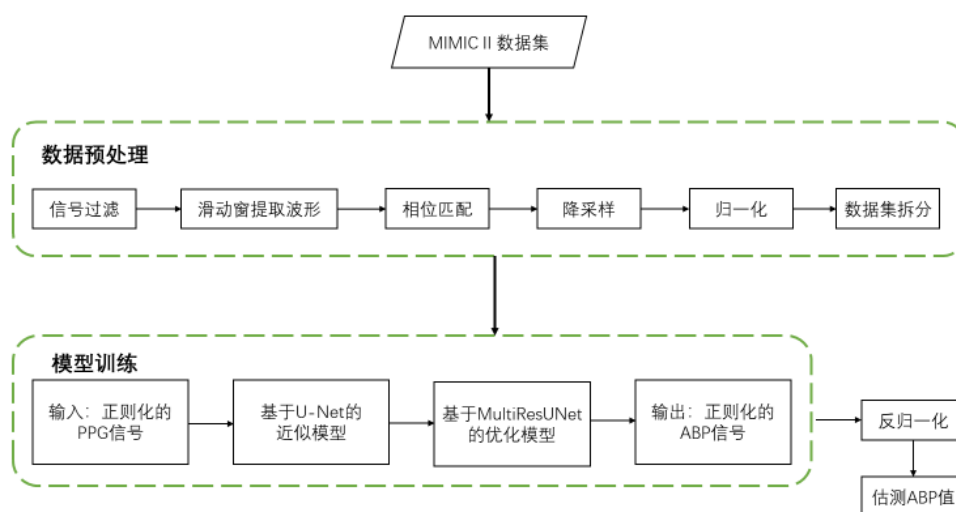


图 1.9 PPG-ABP 直接转换算法流程图

各章节安排如下所示：

第 1 章，介绍了无创血压值测量的背景及意义，详细介绍并对比近年来国内外各类无创血压值测量方法，提出了本文的主要研究内容。

第 2 章，介绍了动脉血压的相关概念及血压波形的特点，明确了 PPG 及动脉血压 ABP 之间的相关性和相似性，进而进一步证明了仅利用 PPG 预测 ABP 的可行性。

第 3 章，介绍了数据来源及预处理方法。

第 4 章，介绍了基于 U-Net 连续血压预测模型的搭建、训练方法、及相关参数的选择。

第 5 章，介绍了实验的结果，检验在不同指标下模型的性能。

第 6 章，总结本文的工作，并阐明改进方向。

1.5 本章小结

（1）本章介绍了无创血压值测量的背景及意义。从国内外各类无创血压预测的方法中总结出主要问题。着重探讨了脉搏波测压法的相关技术难点。

（2）确定本论文主要研究内容。

第2章 脉搏波与动脉血压的联系及相关理论基础

由上章所述，利用心电图信号（ECG）和光电血管容积脉搏波（PPG）信号并结合其他人体生理特征参数可以预测血压值。目前很多研究结合心电图信号（ECG）和光电血管容积脉搏波（PPG）信号对血压进行预测，并取得了良好的结果。但鉴于测量心电图的设备复杂，价格高昂，本文的研究旨在仅利用光电血管容积脉搏波（PPG）信号预测血压。为证明该方法的可行性，本章主要阐述动脉血压的基本概念及其与脉搏波信号（此处主要指光电血管容积脉搏波）之间的相关性，为后文的实验奠定理论基础。

2.1 动脉血压

2.1.1 动脉血压的基本概念

血液对动脉血管的压力被称为动脉血管压力，即为血管内的血压在单位面积上的压力。血压的单位一般采用毫米汞柱（mmHg）。收缩压是心脏在收缩时，主动脉中产生的血压最高压；舒张压是心脏舒张时，主动脉处的血压最低压。平均血压的求取如下公式所示，其中 MAP 表示平均血压，SBP 表示收缩压，DBP 表示舒张压：

$$MAP = \frac{1}{3}SBP + \frac{2}{3}DBP \quad (2)$$




图 2.1 典型动脉血压信号波形图

2.1.2 动脉血压的范围

Chobanian 等人^[26]将动脉血压分为四种类型：

- （1）正常（Normal）：收缩压小于 120 毫米汞柱，舒张压小于 80 毫米汞柱。
- （2）高血压前期（pre-hypertension）：收缩压位于 120-139 毫米汞柱间，舒张压位于 80-89 毫米汞柱间。
- （3）一级高血压（stage-1 hypertension）：收缩压位于 140-159 毫米汞柱间，舒张压位于 90-99 毫米汞柱间。
- （4）二级高血压（stage-2 hypertension）：收缩压大于等于 160 毫米汞柱，舒张压大于等于 100 毫米汞柱。

表 2.1 血压分类^[26]

血压分类	收缩压（毫米汞柱）	舒张压（毫米汞柱）
正常	<120	<80
高血压前期	120-139	80-89
一级高血压	140-159	90-99
二级高血压	≥ 160	≥ 100

2.2 脉搏波及其检测方法

2.2.1 脉搏波信号

心脏的舒张与收缩产生的振动，沿动脉血管和血流向外传播形成脉搏波。具体而言，由于心脏的收缩血液流动速度剧增，导致射入主动脉中致基部压力增加，从而使血管膨胀。心脏舒张时，射血停止，主动脉基部压力下降，管壁恢复原状。动脉血压的变化会施加弹性形变于动脉血管壁上。因此脉搏波携带血压变化信息从主动脉开始向其余身体部位传播。在传播过程中，脉搏波会受血管壁弹性、外周阻力、血液黏度等因素的影响。

一个完整的脉搏波信号如下图所示，其中包含 4 个重要的特征点。A 点为主波，B 点为潮波，C 点为重搏波峰，D 点为重搏波谷。OA 部分为上升支，代表了心脏收缩的阶段。AO' 部分则代表了心脏舒张的阶段。




图 2.2 完整脉搏波波形示意图

2.2.2 检测方法：光电容积脉搏波描记法（PPG）

光电容积脉搏波描记法（PPG）是目前广泛采用的一种测量脉搏波的方法，这种方法测量方便，设备简单^[27]。一个典型的 PPG 器件包括一个 LED 光源和一个光电探测器。LED 光源向皮肤组织发射光线，而光电探测器测量来自皮肤组织的反射光。反射光与血管容积量的变化成正比，因而从反射光强度的变化可以得到血管容积量的变化。同时，由于血管容积可以反应出血流速度，而血流速度又与血压强度有关，因此血管容积变化与血压变化密切相关。


图 2.3 光电容积脉搏波描记法示意图^[28]

图 2.4 光电容积脉搏波描记法原理图

2.3 动脉血压与脉搏波的相关性

如前文所述，动脉血压与脉搏波有很强的相关性，不少研究也支持了此两者的关联性。Martinez^[29]等人分析了动脉血压（ABP）与光电血管容积脉搏波（PPG）在频域和时域的相似性。此两者的皮尔森系数（Pearson's correlation）平均值高于 0.9。由皮尔森系数可知，两者强相关。Abhay^[30]等人主要研究了动脉血压（PPG）与光电血管容积脉搏波（PPG）的特征。他们主要考虑了平均斜率，峰值位置，时间周期，信号幅值等特征。研究发现，动脉血压（ABP）与光电血管容积脉搏波（PPG）的峰值之间存在固定的时间间隔。两个信号的上升时间相差 0.02-0.1s，但是整个的心脏周期时间相同。两者的峰-峰振幅皮尔森系数（Pearson's correlation）为 0.822，也具有很强的相关性。Tusman^[31]等人，研究了 15 个接受心脏外科手术的患者，基于他们的光电血管容积脉搏波（PPG）对其血压值进行分类。该实验取得了极好的结果，准确率达到 98.4%，成功检测低血压和高血压发作率分别为 97.8%。由上可知，动脉血压与光电血管容积脉搏波（PPG）有极强关联。

2.4 本章小结

本章介绍了动脉血压的相关概念及血压波形的特点，并明确了血压的范围及其对应的分类。此外，本章阐述了脉搏波的产生原理，波形特征及光电容积脉搏波描记法（PPG）。最后，本文参考多篇研究文献，明确了光电血管容积脉搏波信号（PPG）及动脉血压（ABP）之间的相关性和相似性，进而进一步证明了仅利用光电血管容积脉搏波（PPG）预测动脉血压（ABP）的可行性。

第3章 数据预处理

本文使用的数据为动脉血压值（ABP）和光电血管容积脉搏波（PPG）。本研究的最终目标是将 PPG 信号输入所搭建的机器学习模型并得到预测的血压值。由于 PPG 信号本身存在一定的噪声，其会对预测模型的准确度造成负面影响，因此需要对信号过滤去噪。此外，鉴于光电血管容积脉搏波和动脉血压值由不同传感器在人体不同部位进行测量，此两者间存在一定的时间间隔。为了能够提高模型预测的准确度，需要使两信号在时域上对齐。综上，为了获得更好的预测结果，在数据输入模型前需要对数据进行处理。本章将对数据来源，数据的信号过滤，滑动窗处理，相位匹配，归一化等前期预处理工作进行详细阐释。

3.1 数据来源

重症监护室多变量智能监数据库 II（MIMIC II）^[32]是 Physionet 提供的在线波形数据库^[33]。MIMIC II 包含 25000 多个实例，表示患者的记录。从每个实例中收集相关信息，包括：

- （1）从置于指尖上的传感器获取的 PPG 信号（频率 125Hz）；
- （2）由有创血压检测获得的 ABP 信号，以毫米汞柱为单位记录（频率 125Hz）；
- （3）心电图机记录的心电图信号（ECG）（频率 125Hz）。

在本文中为了方便数据分析和使用，我们实际使用的是经 Kachuee^[34]等人处理过的 MIMIC II 的数据。该数据集已经经过的处理包括：平均滤波器平滑信号、去除不规则信号、去除不连续信号、信号降噪。

表 3.1 数据概览

实例个数	12000	特征属性	实数
特征个数	3（PPG,ABP,ECG）	是否有缺失值	是

3.2 信号过滤

上述数据已进行初步降噪，但是光电血管容积脉搏波（PPG）中仍存在一些低频噪音。人体的呼吸作用或者微小的动作都可能产生低频噪音，因此需要设计滤波器过滤此噪声。目前的数字滤波器主要包含以下两类：有限冲击响应数字滤波器（FIR）以

及无线冲击响应数字滤波器（IIR）^[28]。由于有限冲击响应滤波器存在较大的延时性，不能满足实时分析的要求。因此本文设计了 IIR-巴特沃斯三阶滤波器去除频率小于 0.1Hz 的噪声分量。巴特沃斯滤波器具有通频带内的频率响应特性曲线平坦，但在阻带则能逐渐减少为零的优点。在 Matlab 中设计巴特沃斯高通滤波器如下所示，设定截止频率为 0.1Hz。

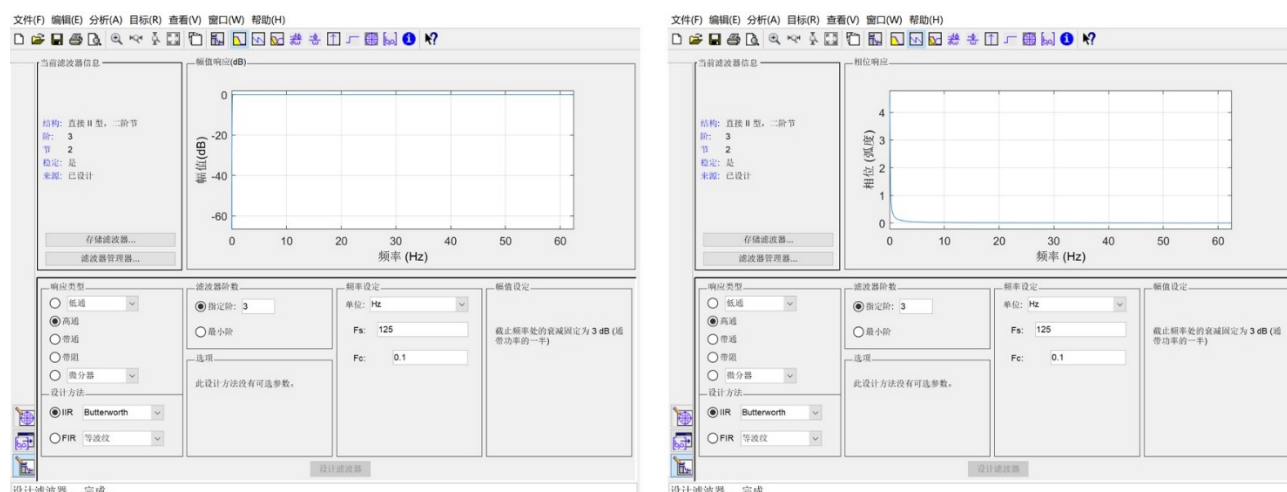


图 3.1 IIR-巴特沃斯三阶滤波器

利用傅里叶变换得到单边频谱图。经过信号过滤后的时域和频域图如下所示。由频域图可知，信号已不存在由呼吸作用等引起的频率小于 0.1Hz 的低频噪声，大于 10Hz 的高频噪声也已被移除。与此同时，对于信号为 50Hz 的工频干扰及高频噪声也已基本消除。经观察发现，所测信号随着时间的增加，极容易出现异常值的现象，故我们对每一个实例最多仅取前 10000 个采样点。




图 3.2 动脉血压信号和光电血管容积脉搏波的时域图




图 3.3 动脉血压信号和光电血管容积脉搏波的频域图

3.3 滑动窗提取波形

在信号过滤后，光电容积脉搏波（PPG）信号和动脉血压（ABP）信号分别利用滑动窗进行提取。具体而言，PPG 和 ABP 均以 10s 为一个样本窗口（即提取 1250 个样本点），为了避免在窗口边界处的信息缺失，其中 5s 为重叠部分（即 625 个样本重叠）。




图 3.4 滑动窗提取波形示意图

3.4 光电容积脉搏波和动脉血压的相位匹配

在观察 ABP 和 PPG 的时域信号时，可以发现这两路信号的峰值间存在一定的时间间隔。这是由于两路信号由不同的传感器在人体不同位置所测得的。如下图所示，动脉血压（ABP）为有创测量方法，其测量部位一般在手臂的肱动脉处。光电血管容积脉搏波（PPG）为无创测量，其测量部位一般在手指指尖。由于两处测量位置存在一定的距离，血液到达的时间并不一致，故导致 PPG 信号相对于 ABP 的信号有一定的相位延迟。为了能减少后续模型计算的复杂程度，需要对 PPG 和 ABP 信号进行相位匹配。




图 3.5 常见动脉血压信号和光电血管容积脉搏波的测量方法

互相关法是一种常见的消除相位延迟的方法。对于连续信号其表达式如下所示：

$$R_{12} = \int_{-\infty}^{+\infty} f_1(t)f_2(t + \tau)dt \quad (3)$$

R_{12} 为 $f_1(t)$ 和 $f_2(t)$ 的互相关函数。在本文中，信号均为采样后的离散信号，对与离散信号 $f_1(t)$ 和 $f_2(t)$ ，其互相关函数如下所示：

$$R_{12} = \sum_{-\infty}^{+\infty} f_1^*(m)f_2(n + m) \quad (4)$$

互相关函数的峰值所对应的横坐标即为两路信号的偏移量。本文首先得到 ABP 和 PPG 的互相关图。A 点为互相关函数的峰值，其所对应的横坐标即为 ABP 和 PPG 之间的相位差。




图 3.6 动脉血压信号和光电血管容积脉搏波的互相关函数

在得到相位差后通过循环位移实现光电容积脉搏波和动脉血压的相位匹配。具体匹配结果如下图所示，可以看出上升支的起始点基本重合，相位匹配效果良好。




图 3.7 动脉血压信号和光电血管容积脉搏波的相位匹配

左图为相位校正前，右图为相位校正后

3.5 动脉血压目标值提取

在进行相位匹配后，接下来进行动脉血压目标值的提取。本文将 PPG 信号输入模型后，得到预测血压值。在预测整体血压值的波形基础上，重点研究对于收缩压（SBP），舒张压（DBP），以及平均血压（MAP）的预测情况。因此需对上述三种血压进行提取，方便和预测血压进行对照。在本文中，三种血压的求取分别为如下公式所示：

$$SBP = \max (ABP) \quad (5)$$

$$DBP = \min (ABP) \quad (6)$$

$$MAP = average (ABP) \quad (7)$$

提取上述三种血压值后，可得总体血压统计分布情况，如下表所示。由统计信息可知，收缩压有较高的标准差，这意味着收缩压数据的离散程度较高，数据分布更广，相对其他数据而言，可能会更难预测。

表 3.2 动脉血压数据的统计信息

	最小值	最大值	平均值	标准差
舒张压（DBP）	50	157	61.94	11.06
平均血压（MAP）	59.75	173.87	88.32	14.25
收缩压（SBP）	72	199	132.58	23.56

3.6 光电容积脉搏波和动脉血压的降采样

本文使用的是较为复杂的深度学习模型，为了能使模型得到充分的训练，同时为了降低模型的计算难度，需要对数据进行降采样，减少数据量。

首先，降低单个周期数据的时间长度。本文仅采用 8.192s（即 1024 个采样点）作为单个信号的长度，换言之我们利用 8.192s 的 PPG 信号预测 8.192s 的 ABP 信号。

其次，将收缩压和舒张压取整，并分别按照血压值大小进行计数。每个收缩压和舒张压都属于某一单一信号周期。在降采样前，取整后的收缩压和舒张压的血压值分布情况如下所示。




图 3.8 降采样前收缩压（左）及舒张压（右）分布图

对于每个不同的收缩压血压值，仅取其中 30% 的信号，若信号数小于 2500 个，则取 2500 个信号周期。对于舒张压信号同理。经过降采样后，总共获得 28929 个信号周期，合计 2836986.368 秒（3949.7728 分钟，65.83 小时）。收缩压和舒张压经过降采样后的分布图如下所示。可以看到收缩压的和舒张压的分布状态与降采样前基本一致，但是血压值总数明显减小。此外，收缩压的分布范围更广，这与上文收缩压的标准差大于舒张压的结果相一致。




图 3.9 降采样后收缩压（左）及舒张压（右）分布图

3.7 归一化及拆分数据集

3.7.1 归一化

为了从信号中提取有意义的信息，有必要对所有信号进行归一化。本文对每一信号周期中的信号采用如下公式进行归一化处理，得到限幅数据。其中， ABP^* 、 PPG^*

代表归一化后的数据， ABP_i 、 PPG_i 代表第*i*个数据值， ABP_{max} 、 PPG_{max} 分别代表 ABP 和 PPG 的最大值， ABP_{min} 、 PPG_{min} 分别代表 ABP 和 PPG 的最小值。

$$ABP^* = \frac{ABP_i - ABP_{min}}{ABP_{max} - ABP_{min}} \quad (8)$$

$$PPG^* = \frac{PPG_i - PPG_{min}}{PPG_{max} - PPG_{min}} \quad (9)$$

3.7.2 数据集的拆分

本研究希望能够将训练好的模型放到真实的血压检测环境中，希望在真实动脉血压预测上能获得较小的结果误差，即泛化误差。为了降低模型的泛化误差，获得更好的预测性能，数据被拆分为三部分，分别是训练集、交叉验证集、测试集。训练集中的数据用来训练模型。交叉验证集上的数据用于优化及挑选模型（例如挑选超参数），平衡模型误差的方差与偏差。测试集上的数据用来代表真实情况下的泛化误差。

由上可知，总共含有 28930 个信号周期，从中随机抽取 5930 个信号周期作为测试集，其余的 23000 个信号周期作为训练集和测试集。

本文使用五折交叉验证。具体而言，23000 个信号周期被随机分为独立的五份相等的数据集。算法总共运行五次，每次取其中的一份数据集为交叉验证集，其余的为训练集。最终将会产生五个模型，其中性能最好的模型将会被最终挑选，并用独立的测试集测试结果。

经过数据拆分后，训练集占总数据的 64%，交叉验证集的比例为 16%，测试集的比例为 20%。

3.8 本章小节

本章具体介绍了本研究所用的数据来源及预处理方法。首先利用 IIR-巴特沃斯三阶滤波器对数据进行低频滤波，并使用滑动窗提取波形周期，利用互相关函数消除 ABP 和 PPG 间的相位差。为减小计算量，降低计算时间，对数据进行了降采样。最后，将 ABP 和 PPG 进行归一化处理，并合理划分训练集、交叉验证集、测试集。本章的数据预处理为后续的模型搭建及预测做好了准备工作。

第4章 基于 U-Net 的连续血压模型

由第一章可知，目前很多基于脉搏波的血压预测都采用特征工程的方法，即提取心电图信号或光电血管容积脉搏波信号中的特征作为模型的输入。基于特征工程的脉搏波预测的前提是所提取的特征与血压信号具有较强的相关性，这才可以使得模型找到血压和特征之间的表达关系。然而受制于研究者对于血压等生理信号的了解，提取的特征可能并不是最佳特征。

在第二章中已详细介绍了动脉血压信号与光电血管容积脉搏波信号之间的强相关性，证明了仅用光电血管容积脉搏波（PPG）信号连续预测动脉血压的可行性。因此本文考虑采用深度神经网络的方法。提出直接输入 PPG 信号而不是输入提取后的特征的方法，通过设计近似模型和优化模型让模型自主从处理过的 PPG 信号中提取有用的特征，最终预测出连续的血压值。具体的步骤如下图所示：




图 4.1 具体步骤示意图

用上述方法的好处在于：

- （1）避免了人工设计及提取特征时无法提取到最优特征；
- （2）保留丰富的脉搏波信息，利于模型对于更高维特征的学习；
- （3）避免个体及人群差异而导致的特征丢失，提高方法的泛化性；
- （4）减少数据前置处理步骤，便于实际应用。

第三章已完成对数据的预处理等无创连续血压测量的前期工作。因此本章主要介绍对于连续血压预测模型的搭建、训练方法、及损失函数的选择。

4.1 环境信息

（1）硬件部分：本研究在数据处理部分使用 CPU，在模型预测部分使用 GPU。CPU 为 E5-2678（2.5GHz，16 核）。GPU 为 2070s，显存为 8GB，显卡数量为 2。实验的平台为 Windos10 操作系统。

（2）软件部分：在数据处理部分使用 Matlab R2020b 编写相关代码。在模型预测部分，近似模型和优化模型均使用 Python 编写，使用的神经网络框架为基于 Tensorflow 的 Keras。

4.2 模型

本文的模型基于 U-Net 及其变体。U-Net 是一种全卷积神经网络。一般将 U-Net 用于图像处理和语义分割。相比于其他卷积神经网络，U-Net 网络能够更加高效的使用数据标签，从而可以用较少的数据，达到更好的预测效果。

如下图所示，该网络结构对称且形状类似于 U，因而被称为 U-Net。U-Net 模型包含编码器和解码器两部分，也可被称作压缩路径和扩展路径。下图的左侧为压缩路径，其利用最大池化层进行下采样，从输入信号中提取空间特征信息输入右侧的扩展路径中。扩展路径进行上采样，逐步还原目标信息。灰色的箭头代表跳跃连接（skip connection），这也是该模型中最为精妙的一点，其有利于解决梯度消失问题和网络退化问题，使得网络更加容易训练。不仅如此，跳跃连接使用叠操作（concatenation），将底层与高层的特征进行融合，降低信息损失，在网络各层中最大化对数据的利用，从而取得更好的结果^[35]。




图 4.2 U-Net 结构示意图

受上述 U-Net 网络模型的启发，本文创新性地将 U-Net 引入一维血压预测，使用两个 U-Net 模型相连接的方式，连续预测血压值。本研究使用近似模型（含深度监督的 U-Net）与优化模型（含深度监督的 MultiResUNet），将输入的 PPG 信号直接转换为连续的 ABP 信号。利用近似模型可以粗略估计出血压轮廓，其输入为经过数据预处理后的光电容积脉搏波信号（PPG）。优化模型以近似模型输出的粗略血压轮廓为输入，进一步优化血压的轮廓，最终得到较为精确的连续血压预测值。

在近似模型的选择上，虽然利用 MultiResUNet 的效果要优于含深度监督的 U-Net，但当和优化模型相连时，总体的表现效果却基本一致。考虑到 MultiResUNet 的计算量远大于含深度监督的 U-Net，因此我们利用含深度监督的 U-Net 作为近似模型而 MultiResUNet 作为优化模型。

下面将具体对上述模型进行介绍。

4.2.1 近似模型




图 4.3 近似模型：深度监督的 U-Net 网络结构示意图

模型的结构图如上所示，与原始模型所不同之处如下：

- (1) **维度变换：**原始的 U-Net 一般是用于处理二维或三维数据，而在血压预测中 PPG 和 ABP 均为一维数据。因此本文在原始 U-Net 模型基础上将 U-Net 中原本二维的卷积层（convolution）、池化层（pooling）和采样操作均相应地更换为一维。
- (2) **激活函数变化：**所有的卷积层除了最后一层均使用 ReLU（Rectified Linear Unit）；为了获得回归的结果，最后的卷积层使用线性激活函数；引入批标准化（Batch Normalized）。
- (3) **深度监督：**在近似模型的 U-Net 模型中引入了深度监督^[36]。深度监督通过使隐藏层的学习过程更加透明和直接，从而达到减少总体误差的作用。该方法作为网络的分支结构，在每个阶段都计算损失函数，最后将不同位置的损失按照系数求和。该方法可以避免当网络深度加深后出现的梯度消失和梯度爆炸问题，使得最终的输出更加优越。
- (4) **损失函数的选择：**在选择损失函数时，考虑了平均绝对误差（MAE）和均方根误差（MSE），其公式分别如下所示：

$$MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} \quad (10)$$

$$MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n} \quad (11)$$

其中 $Y = [y_1, y_2, y_3 \dots]$ 为真实值, $\hat{Y} = [\hat{y}_1, \hat{y}_2, \hat{y}_3 \dots]$ 为预测值。在实验时, 我们发现使用平均绝对误差可以显著地提升正确率。经过合理推测, 这可能是因为近似模型阶段我们仅需要得到一个粗略的血压轮廓, 将每个误差都赋予一样的权重已经可以足够达到本阶段的目的。但是如果我们利用均方根误差, 误差被平方后, 越大的误差会获得更大的惩罚, 在该阶段我们对于输出波形的信息获得较少, 因此过分强调消除较大的误差项实际上可能会降低整体性能。相反, 利用平均绝对误差可以拥有一个虽然粗糙但令人满意的预测效果。

4.2.2 优化模型

考虑到优化模型需要一个更为精准的轮廓, 本文的优化模型基于最后预测效果更好但计算量更大的模型 MultiResUNet^[37]。其与 U-Net 的不同之处如下:

- (1) **多分辨率:** MultiResUNet 的模块将原本 U-Net 的两个 3×3 卷积核替换为 3×3 , 5×5 , 7×7 的三个卷积核的并行运算 (如下图 A 所示)。如下图所示, 5×5 的卷积运算由两个 3×3 的卷积核替代, 7×7 的卷积运算由三个 3×3 的卷积核替代 (如下图 B 所示)。最终用上述多分辨率卷积运算替换了原本 U-Net 中的模块, 并额外引入了 1×1 卷积核 (如下图 C 所示)。

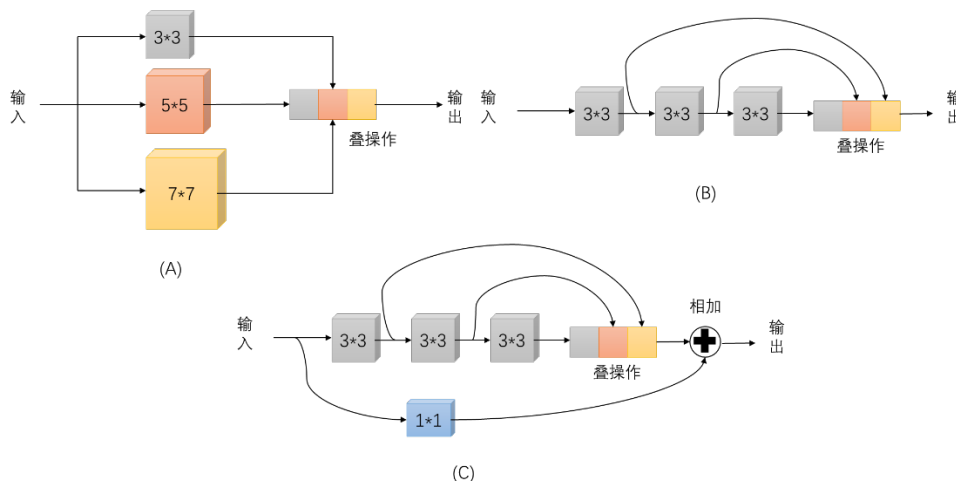


图 4.4 MultiResUNet 的多分辨率卷积运算

- (2) **残差连接**: 将 U-Net 网络中的跳跃连接 (skip connection), 替换为残差连接 (Res Path)。原 U-Net 网络仅仅只是将特征图从压缩路径连接到扩展路径部分。MultiResUNet 则是通过含有残差连接的卷积层链路与扩展路径部分相连。

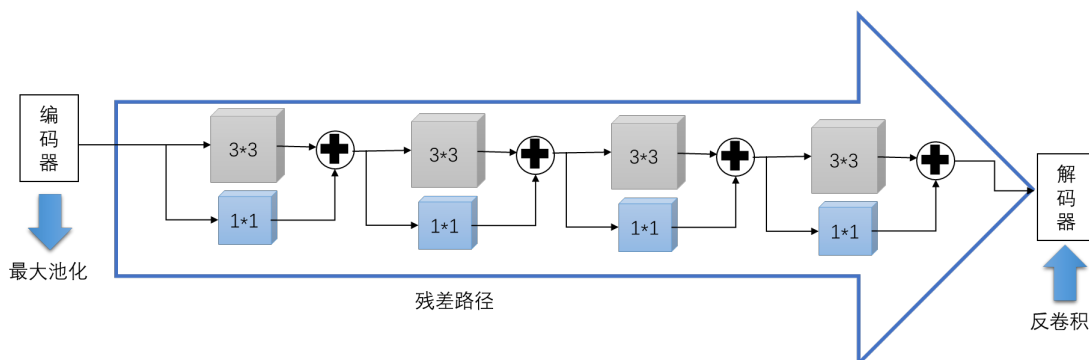


图 4.5 MultiResUNet 的残差连接

本文的优化模型采用了基于 MultiResUNet 的改进模型，改进的方面与近似模型类似，包括维度变换，激活函数变化，深度监督。在损失函数的选择方面略有不同，在优化模型阶段，我们已经得到了对波形的大约估计，因此需要对更大的误差进行更多的惩罚，从而进一步降低误差。所以，此阶段的损失函数选用 MSE（均方根误差）。本文最终所用优化模型如下图所示：




图 4.6 优化模型：深度监督的 MultiResUNet 网络结构示意图

4.3 训练方法

如上文所述，在优化模型中采用绝对平均误差，在近似模型中采用均方根误差。为了进一步降低损失函数，本文采用了 Adam 优化器^[38]。Adam 算法通过梯度的一阶矩和二阶矩的估计，自适应地计算单个参数的不同学习率。它含有的参数包括 β_1 和 β_2 等，上述两参数分别控制一阶矩和二阶矩的衰减率。本文采用的参数与原始论文相同，即 $\beta_1 = 0.99$ ， $\beta_2 = 0.999$ 。每个模型的迭代次数均为 100 次。

4.4 本章小节

本文的研究方法是将 PPG 信号先通过一个近似模型的到一个粗略的血压轮廓，再将经近似模型处理后的信号输入优化模型，最后得到连续血压预测值。本文将原本用于图像处理的 U-Net 模型创新性地用于一维血压预测中。本章主要介绍了模型搭建，包括搭建基于的硬件设备、软件信息、模型算法、训练方法等。本章提出了一个含有深度监督的 U-Net 新型血压预测网络模型，其创新点在于引入了深度监督和批标准化。此外，本章还提出了一个改进的基于 MultiResUNet 的血压预测优化模型。最后，本章详细介绍了训练方法及训练中的有关参数选择。

第 5 章 基于 U-Net 网络的连续血压模型的实现与结果分析

第四章主要对模型的结构及训练方法进行了介绍，本章将重点介绍实验的结果，并综合对比实验中的不同模型，得出最优模型组合作为 PPG-ABP 直接转换模型。其次，检测模型在各种标准下（如英国高血压协会，美国国家标准机构等）的表现结果。最后，将本文的模型与现有的血压预测结果进行比对。

本文共采用了 5 种模型组合并对其均进行了实验验证。模型组合信息如下表所示：

表 5.1 模型组合信息

组合	近似模型	优化模型
1	UNet64DS	MultiResUNet
2	UNet32	MultiResUNet
3	UNet64	MultiResUNet
4	UNet64	MultiResUNetDS
5	UNet64DS	MultiResUNetDS

下面对模型进一步讲解：

- （1）UNet64DS：含有 64 个卷积滤波器的改进 U-Net 网络，同时在模型中应用了深度监督；
- （2）UNet32：含有 32 个卷积滤波器的改进 U-Net 网络，同时在模型中未应用深度监督；
- （3）UNet64：含有 64 个卷积滤波器的改进 U-Net 网络，同时在模型中未应用深度监督；
- （4）MultiResUNet：MultiResUNet 网络，在模型中未应用深度监督；
- （5）MultiResUNetDS：MultiResUNet 网络，在模型中应用深度监督。

5.1 对比实验

如第三章模型处理所言，本文采取了五折交叉验证的方式。通过将数据集分成 5 个部分，每个模型都训练五次的方法，来挑选各个模型训练结果下的最优超参数。各模型的五折交叉验证的结果如下表所示

（1）近似模型

近似模型主要是基于 U-Net 模型，总共包含三个模型分别是 UNet64DS，UNet32，以及 UNet64。每个组合的最优结果均标粗示意。

表 5.2 UNet64DS 五折交叉验证结果

UNet64DS		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.105317	0.202673
1	0.109526	0.207624
2	0.105505	0.208011
3	0.100033	0.204165
4	0.097154	0.202796

表 5.3 UNet32 五折交叉验证结果

UNet32		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.02139	0.050218
1	0.022263	0.049996
2	0.02069	0.05074
3	0.021072	0.048959
4	0.021468	0.049265

表 5.4 UNet64 五折交叉验证结果

UNet64		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.02139	0.050218
1	0.022263	0.049996
2	0.02069	0.05074
3	0.021072	0.048959
4	0.021468	0.049265

（2） 优化模型

优化模型主要是基于 MultiResUNet，一种是带有深度监督的模型，一种是未带有深度监督的模型，下面将展示不同组合下的最终预测结果，将每个模型的最优结果均标粗示意。

表 5.5 组合 1 五折交叉验证结果

组合一：UNet64DS+MultiResUNet		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.000319	0.005293
1	0.000343	0.005149
2	0.000332	0.005425
3	0.000298	0.005287
4	0.000368	0.005327

表 5.6 组合 2 五折交叉验证结果

组合二：UNet32+MultiResUNet		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.000283	0.005459
1	0.000383	0.005197
2	0.00025	0.005582
3	0.000294	0.005348
4	0.00029	0.005401

表 5.7 组合 3 五折交叉验证结果

组合三：UNet64+MultiResUNet		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.00025	0.005217
1	0.000249	0.004953
2	0.000268	0.005247
3	0.000256	0.005205
4	0.000254	0.005282

表 5.8 组合 4 五折交叉验证结果

组合四：UNet64+MultiResUNetDS		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.001895	0.020277
1	0.002011	0.019343
2	0.001933	0.020253
3	0.001949	0.020188
4	0.001992	0.020395

表 5.9 组合 4 五折交叉验证结果

组合五：UNet64DS +MultiResUNetDS		
折数	训练集的损失函数	交叉验证集的损失函数
0	0.003477805	0.020575494
1	0.003700083	0.019673983
2	0.003451937	0.021305661
3	0.003428874	0.020612637
4	0.003436857	0.020412749

基于上述交叉验证，选择每个组合中表现最为优异的模型测试他们的平均误差，以此作为挑选最佳模型的依据，各组合的平均误差如下所示：

表 5.10 各模型的平均误差

组合	近似模型	优化模型	ME(DBP SBP)
1	UNet64DS	MultiResUNet	3.628 -9.365
2	UNet32	MultiResUNet	1.726 -8.31
3	UNet64	MultiResUNet	3.054 -7.455
4	UNet64	MultiResUNetDS	2.732 -5.03
5	UNet64DS	MultiResUNetDS	1.087 -3.791

由上可知，本研究最后采用的模型（组合五）的平均误差最小。对比组合 1 和组合 5，由于组合 5 的 MultiResUNet 加入了深度监督，舒张压的平均误差从 3.628 降低至 1.087，收缩压的平均误差从-9.365 降低至-3.791；对比组合 4 和组合 5，由于组合 5 的 UNet64 加入了深度监督，舒张压的平均误差从 2.732 降低至 1.087，收缩压的平均误差由-5.03 降低至-3.791。对比组合 1 和组合 3，模型中仅在 UNet64 中引入深度监督，对

于模型没有明显的提升。对比组合 3 和组合 5，模型中仅在 MultiResUNet 中引入深度监督，对于模型性能有显著提升。综上，在 MultiResUNet 中加入深度监督对模型性能的提升大于 UNet64 加入深度监督。两者同时采用深度监督时，平均误差最小，模型性能最优，这证实了本文采用的改进模型的有效性。

5.2 结果检验

本研究最为重要和独特的一点是能将 PPG 信号直接转换为相对应的血压波形。尽管根据之前的研究，PPG 和 ABP 之间具有一些相关性，但这两种型号在波形上还是有很大差异的。本文提出的 PPG-ABP 直接转换模型，在预测血压波形时，仅仅将 PPG 信号作为输入。该方法主要含有两个步骤。第一个是近似模型网络，PPG 信号通过该网络后可以得到一个粗略估计的血压波形。第二阶段是优化模型，其输入为第一阶段的粗略波形，从而可以得到更为精准的血压预测波形。正如 3.5 节所言，由于收缩压的标准差更大，这意味着其数据的离散性更高，也更难以预测。本文在预测结果上，对于舒张压和平均血压的预测结果明显好于收缩压。预测的结果如下表所示：

表 5.11 测试误差

	平均绝对误差 (MAE)	均方根误差(RMSE)
舒张压	10.1	6.2
收缩压	19	13
平均血压	9.5	6.1

5.2.1 预测血压波形

本节将展示预测血压波形，为便于分析预测结果，将血压真实值划分为规则周期血压波形，不平滑血压波形，突变血压波形，不规则不周期血压波形。由下图可知，由于在数据处理部分经过相位匹配，预测血压的峰值和真实血压的峰值所出现的时间都基本吻合。所提出的模型对于真实血压有较好的拟合效果。

（1）规则周期血压波形

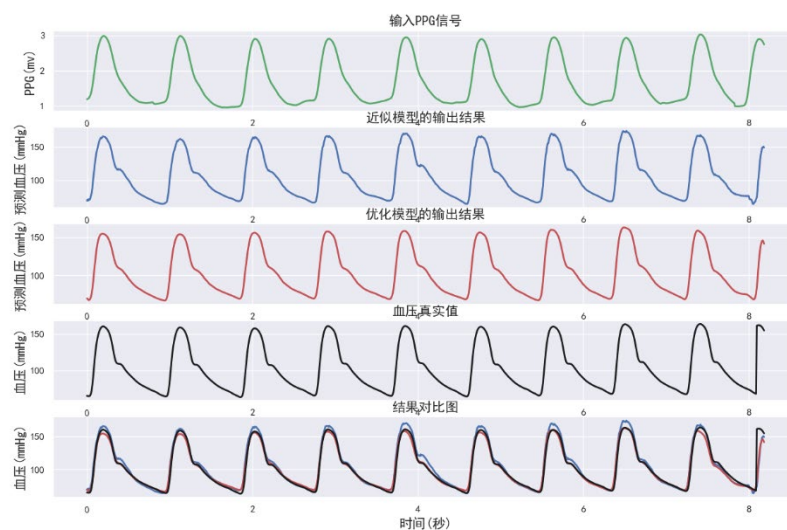


图 5.1 规则周期血压波形预测图

如上图所示，对于周期血压模型，本文提出的方法有较好的拟合效果。尽管近似模型可以大致拟合血压轮廓，其在峰值处的拟合不如优化模型。在近似模型的粗略拟合后，使用优化模型可以进一步提升拟合精度。

（2）不平滑血压波形




图 5.2 不平滑血压波形预测图

如上图所示，对于不平滑的血压波形，用本文提出的方法可以对血压进行平滑处理，同时也能达到较好的预测效果。在峰值处，近似模型的预测值远低于真实

值，使用优化模型可以明显提升拟合精度。

（3） 突变血压波形




图 5.3 突变血压波形预测图

如上图所示，对于突变血压模型，本研究所提出的方法不能很好的预测。由上图可知，在 3-4s 间，波形发生突变，不再遵循先上升后下降的周期性规律，但其预测波形仍会遵循周期性规律，未能很好地预测突变部分。

（4） 不规则不周期血压波形




图 5.4 不规则不周期血压波形预测图

如上图所示，对于完全不规则的不周期的 PPG 信号输入，模型不能提供较好的拟

合效果。

5.2.1 血压检验标准

当前血压有众多检验标准，目前最为公认的标准为英国高血压学会（BHS）标准和美国医疗仪器促进协会（AAMI）标准。

英国高血压学会提出了一种结构化的评价标准，这种评价标准被广泛应用于目前的研究中。BHS 的准确度指标基于绝对误差。具体来说，通过计算多少测试样本分别低于 5 毫米汞柱、10 毫米汞柱、15 毫米汞柱来确定评价等级。如果一个方法想要获得某个等级，该方法必须在收缩压、舒张压、平均血压上同时都达到这一等级的标准。




图 5.5 绝对误差直方图

本文的收缩压、舒张压、平均血压的绝对误差及其分布如上所示。对于舒张压和平均血压，大部分的绝对误差均低于 15 毫米汞柱，而且有很大一部分低于 5 毫米汞柱。在英国高血压协会的标准下，使用本文所提出的方法，舒张压和平均血压的预测可以达到等级 B，预测性能良好。

本文对于收缩压的预测效果较差，仅为等级 D。多篇论文显示，利用本文所用的数据集（全部或大部分使用来自 MIMIC II 数据库的数据）在收缩压上的最好预测效果仅能达到等级 B（详情见 5.3 节），这说明本数据集中收缩压较难预测。其次，正如上文 3.5 节所述，收缩压的分布范围更广，标准差更大，其预测难度会高于收缩压和平均血压。

表 5.12 英国高血压协会标准

		累计误差比例		
		≤5 毫米汞柱	≤10 毫米汞柱	≤15 毫米汞柱
结果	舒张压	60.70%	83.00%	91.60%
	平均血压	60.50%	81.60%	90.80%
	收缩压	32.60%	54.90%	69.30%
BHS 标准	等级 A	60%	85%	95%
	等级 B	50%	75%	90%
	等级 C	40%	65%	85%

与英国高血压协会标准类似，美国医疗仪器促进协会标准也是被广泛使用的衡量指标。它的评价指标主要依赖于平均误差和标准差。若测试结果满足平均误差小于 5 毫米汞柱，标准差小于 8 毫米汞柱，则符合该标准。如误差分布图所示，收缩压、舒张压、平均血压的分布均近似于正态分布，误差为 0 处的样本最多。对于收缩压，其误差分布范围最广，在正误差处分布少于负误差处，说明模型对于收缩压的预测一般都会小于真实值；对于舒张压，其误差分布主要集中于正误差处，说明模型对于舒张压的预测一般都会大于真实值；对于平均血压，误差分布范围最小，正负误差分布范围也基本一致，这可能由于平均血压的误差是收缩压和舒张压中和了的结果。




图 5.6 误差分布图

如下表所示，舒张压、平均血压以及收缩压的平均误差均小于 5 毫米汞柱。其中，平均血压的平均误差最小，仅为 0.583 毫米汞柱。此外，平均血压的标准差小于 8 毫米汞柱，满足美国医疗仪器促进协会标准。平均血压的预测性能优良可能由于其值为舒张压和收缩压加权相加所得，综合了舒张压的正误差（1.087）和收缩压的负误差（-3.791），因而得到了较小的平均误差。

表 5.13 美国医疗促进协会标准

		平均误差	标准差	样本数量
结 果	舒张压	1.087	10.112	184
	平均血压	0.583	7.93	184
	收缩压	-3.791	18.623	184
AAMI 标准		≤ 5	≤ 8	≥ 85

5.2.2 血压分类

从临床应用角度而言，预测是否是高血压的状态比获取正确的收缩压、舒张压或平均血压的值更加重要。本文参照 2.1.2 节，将血压分为正常、高血压前期、一级高血压以及二级高血压。从临床而言，往往更重视对正常状态、高血压前期以及高血压的区分。因此将一级高血压以及二级高血压合并为高血压。最终，本文以上述三类标签进行分类，分类结果如下所示。




图 5.7 预测分类结果：混淆矩阵

表 5.14 使用舒张压的预测分类结果

使用舒张压进行血压分类				
	精确度	召回率	F1	支持样本数
正常	0.89	0.99	0.94	4935
高血压	0.91	0.28	0.43	459
高血压前期	0.48	0.31	0.38	536

表 5.15 使用收缩压的预测分类结果

使用收缩压进行血压分类				
	精确度	召回率	F1	支持样本数
正常	0.89	0.34	0.5	551
高血压	0.85	0.98	0.91	4310
高血压前期	0.61	0.44	0.51	1069

由上可知，使用舒张压可以较好地地区分出正常血压水平的人群，其 F1 值可达 94%。使用收缩压可以较好地地区分处高血压人群，其 F1 值可达 91%。对于高血压前期，分类结果较差，这主要由于其分布范围较窄，对于预测要求较高（收缩压 120-139 毫米汞柱，舒张压 80-89 毫米汞柱）。

5.2.3 统计分析

Bland-Altman 图是用来检测所提出方法与真实值之间的一致性，其提出计算两种结果的“95%的一致性界限”（如下图虚线所示，在虚线内的点都表示误差结果处于 $\text{Mean}(\text{error}) \pm 1.96\text{STD}$ ，即具有良好的一致性）。

由下图结果可知，舒张压和平均血压的预测可以较好地符合一致性预测。（1）对于收缩压，其误差分布点较为离散。（2）对于舒张压，在 50-70 毫米汞柱间，舒张压的预测误差基本都在一致性界限内，随着血压值的上升，预测误差增加，在 100-120 毫米汞柱间有极异常点。高舒张压可能属于极异常波形，其在数据集中样本较少不易学习，从而导致对于这一部分的舒张压难以预测，误差较大。（3）对于平均血压，小于 80 毫米汞柱的预测误差基本都在一致性界限内，与收缩压类似，随着血压值上升，预测误差增加，在 120-140 毫米汞柱间有极异常点。上述现象的原因可能和真实值所属波形为异常突变波形有关。




图 5.8 Bland-Altman 图

回归预测可以看出预测值和真实值之间的相关性。由下图可知，舒张压、平均血压、收缩压与真实值之间的皮尔森系数分别为 0.47、0.65、0.64。说明预测值平均血压和收缩压与真实值之间高度相关，而预测值舒张压与真实值之间中度相关，收缩压与真实值之间相关度较低。上述皮尔森系数基于 5930 个样本，其 p 值小于 0.000001，证实了零假设，即证明了本文结果在统计上的显著性。上述结果，说明了对于平均血压的预测结果最优，舒张压次之，收缩压的预测结果最不理想。这与上文诸多检验结果相一致。




图 5.9 回归图

5.3 与现有工作的比较

尽管有很多利用机器学习预测血压的方法，但是我们的方法不能直接和他们进行比较。不同的数据集以及不同的数据量，都会导致不同的预测结果。目前很多研究使用的是不对外公开的数据集；对于使用公开数据集的研究（例如本文所使用的 MIMIC

II 数据集），不同研究仍采用不同的样本数目。为了使比较范围基本一致，本文选用了实验数据均来自 MIMIC II 数据集的研究，并采用 BHS、AAMI、MAE 等标准进行横向比较。对比结果如下表所示。

从衡量标准上：本文在使用 BHS 标准下，性能较为良好，舒张压和平均血压均能达到等级 B 的水平。而另外的研究在 BHS 标准下的表现均不如本文理想。

从输出信号上：另外两篇文献仅能单独预测收缩压、舒张压、平均血压等值，而不能连续预测动脉血压波形。

从输入信号：除了 PPG 信号外，文献一、二还需使用心电图（ECG）信号。他们所需信号类型更多，信号处理更复杂，且用到的样本容量更大。本文使用较小样本容量，便可达到较好的预测效果。

表 5.16 研究结果对比

	样本人数	BHS	AAMI	MAE
本文结果	184	舒张压：B 平均血压：B 收缩压：等级 D	平均血压	舒张压：10.1 收缩压：19 平均血压：9.5
文献 1 ^[39]	942	舒张压：B 平均血压：C 收缩压：等级 D		舒张压：6.34 收缩压：12.38 平均血压：7.52
文献 2 ^[40]	942	舒张压：B 平均血压：C 收缩压：等级 D	平均血压 舒张压	舒张压：5.35 收缩压：5.92 平均血压： 11.17

5.4 本章小结

本章主要对实验结果进行阐释。首先介绍了通过五折交叉验证选取最优模型，并借助平均误差选取最优模型组合的过程。其次，对实验结果进行了检验。在预测血压波形上，近似模型可以输出一个粗略的血压轮廓，经过优化模型后，可以进一步提升血压拟合效果。本文提出的方法可以较好地拟合规则周期血压波形，对于原本不平滑

的血压波形在预测时会平滑处理。但本文对于突变血压波形以及不规则不周期的血压波形，拟合效果并不理想。在英国高血压协会标准下，本文提出的方法可以使舒张压和平均血压的预测达到等级 **B**。在美国医疗仪器促进协会标准下，本文提出的方法可以使平均血压的预测满足该标准。

血压的分类比实际血压值预测更具有临床意义。利用本文提出的方法，若使用舒张压进行血压分类，可以很好地区分出正常血压人群，F1 值达 **94%**；若使用收缩压进行血压分类，可以很好地区分出高血压人群，F1 值达 **91%**。

本章还使用了 Bland-Altman 图检验预测结果的一致性。结果显示舒张压和平均血压的预测可以较好地符合一致性预测。从回归预测上，可以看出预测血压和真实血压间存在相关性，以及统计上的显著性。

最后，本文将结果与现有结果进行对比。在 **BHS** 标准下，本文所用方法优于上文提到的两篇文献。除了预测结果在某些方面具有一定的优越性外，本文所提方法仅需使用 **PPG** 信号，便可预测出相对应的全部血压波形。相对于现有研究成果，本模型可以使用更少的信号来源及信号样本，并提供更丰富的输出血压波形信息。但本文对于收缩压的预测仍有很大的进步空间。

第 6 章 总结与展望

6.1 工作总结

本文在综合分析国内外基于机器学习的无创血压连续预测的基础上，提出了一种基于光电血管容积脉搏波信号的 PPG-ABP 直接转换模型。该模型由两部分组成，第一部分为基于 U-Net 的近似模型，其输入为经过数据处理后的 PPG 波形。经过近似模型后，输出粗略的血压轮廓。第二部分为基于 MultiResUNet 的优化模型，其接受来自第一部分的输出作为输入，并进一步优化血压预测结果。

具体研究工作，总结如下：

- 1) 分析国内外研究论文，阐明了 PPG 与 ABP 信号之间的相关性，从而证实了本文提出的 PPG-ABP 直接转换模型在理论上的可行性。
- 2) 完成针对重症监护室多变量智能监数据库 II 的数据预处理工作，并取得良好效果。
 - 针对 PPG 的噪声特点，设计 IIR-巴特沃斯三阶滤波器；
 - 利用滑动窗提取波形；
 - 针对 PPG 和 ABP 信号存在相位延迟的现象，利用互相关函数实现相位匹配；
 - 为进一步降低计算时间，根据数据分布特征，对数据集进行了降采样；
 - 完成对 ABP 和 PPG 型号的归一化处理，并合理拆分数据，使用五折交叉验证。
- 3) 提出 PPG-ABP 直接转换模型，测试结果表明该模型有较好的预测性能
 - 设计基于 U-Net 的近似模型。本文针对血压信号特点，对 U-Net 模型进行了改进，在 U-Net 模型基础上引入了深度监督和批处理等操作。并更改了维度、激活函数、损失函数等。
 - 设计基于 MultiResUNet 的优化模型。针对输入信号特点，对 MultiResUNet 模型进行了合理的改进，并选用合适的超参数。
 - 利用五折交叉验证，挑选最佳模型组合。
 - 结果检验。本文所提出方法可以较好地拟合一般血压波形，对于突变和极度不规则的血压波形拟合效果不理想。在英国高血压协会（BHS）标准下，

本文对于舒张压和平均血压的预测可以达到 B 级。对于平均血压的预测满足美国医疗仪器促进协会（AAMI）标准；对于血压分类，本文方法可以很好地区分正常血压和高血压人群。通过统计分析，本文预测结果符合一致性和统计上的显著性。

相较于其他研究，本文的优点如下

- （1） 本文所提方法使用较小的样本容量便可达到较优的预测效果。
- （2） 无需手动提取特征。目前的一些研究需要手动提取特征，对于异常波形，无法提取到规定特征。此外，受制于研究者知识背景影响，所提取的特征和血压并不具有高度相关性。本文所提方法，是基于非特征的模型预测。模型会自动找到最优特征。
- （3） 在信号获取上更为便捷。目前的研究大多结合心电图信号（ECG）和光电容积脉搏波信号（PPG）预测血压值。然而心电图的设备复杂、价格高昂。本文所提出的方法，可以仅使用 PPG 信号预测，减少了设备采集及信号处理的复杂程度。
- （4） 在结果输出上包含更丰富的信息。目前的研究主要针对预测收缩压、舒张压、平均血压等单一值，较少能连续预测血压波形。本文的模型可以连续预测血压波形，从而给医护工作者提供更丰富的生理信息。

6.2 研究展望

本文提出的 PPG-ABP 直接转换模型已能较好地预测血压连续波形，为了进一步减少预测误差，降低训练时间，以下方面仍有研究空间：

- （1） 本文在构建网络模型时未考虑模型对电脑性能的要求，设计的模型较为复杂，训练时占用极大的内存及显存。为了能够训练顺利，被迫减小批尺寸（batch size），使得模型的损失函数震荡，不易收敛，训练时间被迫增长。因此，后续的研究应考虑简化模型结构。
- （2） 受制于时间因素，各超参数还未调整至最优阶段，下一步可以继续优化超参数的选择，从而提高预测结果。
- （3） 本文将信号长度统一为 8.192s 进行训练，未考虑时间长度对于预测性能的负面影响，下一步可以研究更长信号下的血压预测模型设计。

参考文献

- [1] El-Hajj C , Kyriacou P A . A review of machine learning techniques in photoplethysmography for the non-invasive cuff-less measurement of blood pressure[J]. Biomedical Signal Processing and Control, 2020, 58:101870-.
- [2] SOLà J. Continuous non-invasive blood pressure estimation [D], 2011.
- [3] INVESTIGATORS S H, THAMBAR S, NANRA R S. Catheter-based renal sympathetic denervation for resistant hypertension durability of blood pressure reduction out to 24 months | NOVA. The University of Newcastle's Digital Repository [J]. Hypertension, 2011, 57(5): 911-7.
- [4] 袁春雨. 基于 GA-Elman 神经网络的无创连续血压测量方法的研究 [D]; 吉林大学, 2019.
- [5] IBTEHAZ N, RAHMAN M S. PPG2ABP: Translating Photoplethysmogram (PPG) Signals to Arterial Blood Pressure (ABP) Waveforms using Fully Convolutional Neural Networks [J]. 2020,
- [6] KURTZ T W, GRIFFIN K A, BIDANI A K, et al. Recommendations for blood pressure measurement in humans and experimental animals. Part 2: Blood pressure measurement in experimental animals: a statement for professionals from the subcommittee of professional and public education of the American Heart Association [J]. Hypertension, 2005, 45(2): 299-310.
- [7] RAMSEY M. Blood pressure monitoring: Automated oscillometric devices [J]. 1991, 7(1): 56-67.
- [8] PRESSMAN G L, NEWGARD P M. A Transducer for the Continuous External Measurement of Arterial Blood Pressure [J]. IEEE Transactions on Bio-medical Electronics, 1963, 10(2): 73-81.
- [9] 于潇, 林君, 李肃义. 无创血压测量技术的发展概况 [J]. 广东医学, 2012, 33(15): 2356-9.
- [10] 汤池, 杨国胜, 席涛. 无创连续血压测量方法的研究进展 [J]. 医疗卫生装备, 2004, 025(010): 26-7,34.
- [11] PENÁZ J, VOIGT A, TEICHMANN W. [Contribution to the continuous indirect blood pressure measurement] [J]. Zeitschrift Für Die Gesamte Innere Medizin Und Ihre Grenzgebiete, 1976, 31(24): 1030-3.
- [12] YAMAKOSHI K I, SHIMAZU H, TOGAWA T. Indirect measurement of instantaneous arterial blood pressure in the rat [J]. The American journal of physiology, 1979, 237(5): H632-7.
- [13] 朱丽娟, 李恩有, 孙波. 血压监测方法的研究现状 [J]. 医学综述, 2017, 13):
- [14] LI Y-H H, LATIFA N.; PURWANDARI, KARTIKA; LIN, YUE-DER. Real-Time Cuffless Continuous Blood Pressure Estimation Using Deep Learning Model [J]. Sensors, 2020, 20(
- [15] TANVEER S, HASAN M. Cuffless Blood Pressure Estimation from Electrocardiogram and Photoplethysmogram Using Waveform Based ANN-LSTM Network [M]. 2018.
- [16] LI Y-H, HARFIYA L N, PURWANDARI K, et al. Real-Time Cuffless Continuous Blood Pressure Estimation Using Deep Learning Model [J]. Sensors, 2020, 20(19): 5606.
- [17] CAREK A M, CONANT J, JOSHI A, et al. SeismoWatch: Wearable Cuffless Blood Pressure Monitoring Using Pulse Transit Time [J]. Proceedings of the ACM on interactive, mobile, wearable and ubiquitous technologies, 2017, 1(3):
- [18] CHEN S, JI Z, WU H, et al. A Non-Invasive Continuous Blood Pressure Estimation Approach Based on Machine Learning [J]. Sensors (Basel, Switzerland), 2019, 19(
- [19] TENG X F, ZHANG Y T. Continuous and noninvasive estimation of arterial blood pressure using a photoplethysmographic approach; proceedings of the International Conference of the IEEE Engineering in Medicine & Biology Society, F, 2003 [C].
- [20] WANG L, WEI Z, YING X, et al. A Novel Neural Network Model for Blood Pressure Estimation Using Photoplethysmography without Electrocardiogram [J]. Journal of Healthcare Engineering, 2018, (2018-3-7),

2018, 2018(1-9).

- [21] XIE Q, WANG G, PENG Z, et al. Machine Learning Methods for Real-Time Blood Pressure Measurement Based on Photoplethysmography; proceedings of the 2018 IEEE 23rd International Conference on Digital Signal Processing (DSP), F, 2018 [C].
- [22] SLAPNIČAR G, MLAKAR N, LUŠTREK M. Blood Pressure Estimation from Photoplethysmogram Using a Spectro-Temporal Deep Neural Network [J]. *Sensors*, 2019, 19(15): 3420.
- [23] SHOTA, SHIMAZAKI, HARUKI, et al. Cuffless Blood Pressure Estimation from only the Waveform of Photoplethysmography using CNN; proceedings of the 2019 41st Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC), F, 2019 [C].
- [24] XING X, SUN M. Optical blood pressure estimation with photoplethysmography and FFT-based neural networks [J]. *Biomedical Optics Express*, 2016, 7(8): 3007.
- [25] DEY J, GAURAV A, TIWARI V. InstaBP: Cuff-less Blood Pressure Monitoring on Smartphone using Single PPG Sensor [M]. 2018.
- [26] CHOBANIAN A V, BAKRIS G L, BLACK H R, et al. The Seventh Report of the Joint National Committee on Prevention, Detection, Evaluation, and Treatment of High Blood Pressure: the JNC 7 report [J]. *Jama*, 2003, 289(19): 2560-72.
- [27] DENISSE, CASTANEDA, AIBHLIN, et al. A review on wearable photoplethysmography sensors and their potential future applications in health care [J]. *International journal of biosensors & bioelectronics*, 2018, 4(4): 195-202.
- [28] 司玉娟, 王月猛, 刘立勋, et al. 基于 Elman 神经网络的云端连续血压测量方法及系统, CN106821356B [P/OL]. 2019-08-27].
- [29] MARTÍNEZ G, HOWARD N, ABBOTT D, et al. Can Photoplethysmography Replace Arterial Blood Pressure in the Assessment of Blood Pressure? [J]. *Journal of clinical medicine*, 2018, 7(10):
- [30] ABHAY T, KAYALVIZHI N, ROLANT G J. Estimating Correlation between Arterial Blood Pressure and Photoplethysmograph [M]. *The 17th International Conference on Biomedical Engineering*, 2017.
- [31] TUSMAN G, ACOSTA C M, PULLETZ S, et al. Photoplethysmographic characterization of vascular tone mediated changes in arterial pressure: an observational study [J]. *Journal of Clinical Monitoring and Computing*, 2019, 33(5): 815-24.
- [32] SAEED M, VILLARROEL M, REISNER A T, et al. Multiparameter Intelligent Monitoring in Intensive Care II: a public-access intensive care unit database [J]. *Critical Care Medicine*, 2011, 39(5): 952.
- [33] GOLDBERGER A. PhysioBank, PhysioToolkit, and Physionet : Components of a new research resource for complex physiologic signals [J]. *Circulation*, 2000, 101(
- [34] KACHUEE M, KIANI M M, MOHAMMADZADE H, et al. Cuff-less high-accuracy calibration-free blood pressure estimation using pulse transit time [J]. *Annals of Pure & Applied Logic*, 2015, 63(3): 271–81.
- [35] 曹江华. 复杂背景下非结构化道路可行驶区域检测研究 [D]; 浙江科技学院, 2020.
- [36] LEE C Y, XIE S, GALLAGHER P, et al. Deeply-Supervised Nets [J]. *Eprint Arxiv*, 2014, 562-70.
- [37] IBTEHAZ N, RAHMAN M S. MultiResUNet : Rethinking the U-Net architecture for multimodal biomedical image segmentation [J]. *Neural Networks*, 2019, 121(
- [38] KINGMA D, BA J. Adam: A Method for Stochastic Optimization [J]. *Computer Science*, 2014,
- [39] KACHUEE M, KIANI M M, MOHAMMADZADE H, et al. Cuff-less high-accuracy calibration-free blood pressure estimation using pulse transit time; proceedings of the IEEE International Symposium on Circuits & Systems, F, 2015 [C].
- [40] KACHUEE M, KIANI M M, MOHAMMADZADE H, et al. Cuffless Blood Pressure Estimation

Algorithms for Continuous Health-Care Monitoring [J]. IEEE Trans Biomed Eng, 2017, PP(4): 859-69.